Machine Learning

OS 4 TIPOS, ALGORITMOS E SUAS FUNÇÕES

Área da IA que permite aos computadores aprender padrões a partir de dados e usar esse aprendizado para prever, classificar, agrupar ou decidir, sem que todas as regras precisem ser programadas manualmente.

Em termos simples: damos dados a um algoritmo, ele identifica padrões e, depois do treinamento, aplica esses padrões a novos dados.

01 Supervisionado

O modelo recebe exemplos em que as entradas (X) já têm uma resposta conhecida (y). O objetivo é aprender a relação entre X e y para prever em novos dados.

→ Rotulados: SIM · Objetivo: prever · Saída: classe ou valor.

Tipos de problema

As duas grandes tarefas do aprendizado supervisionado.

Classificação

Prevê categorias.

→ Spam ou não spam.

Regressão

Prevê valores numéricos.

→ Preço de uma casa.

Algoritmos

Principais algoritmos supervisionados e para que servem.

Regressão Linear

Prevê valores numéricos assumindo relação aproximadamente linear entre as variáveis.

→ Preço, vendas, demanda.

Regressão Logística

Estima a probabilidade de uma classe. Apesar do nome, é usada principalmente para classificação.

→ Fraude, doença, aprovação.

Árvore de Decisão

Cria regras em forma de árvore para dividir os dados e chegar a uma previsão.

→ Classificação e regressão.

Random Forest

Combina várias árvores de decisão para obter previsões mais robustas.

→ Classificação, risco e previsão.

KNN

Classifica ou prevê com base nos exemplos mais próximos no espaço de características.

→ Reconhecimento de padrões e classificação.

SVM

Encontra uma fronteira que separa as classes, buscando maximizar a margem entre elas.

→ Classificação de textos e imagens.

Naive Bayes

Usa probabilidades e a hipótese simplificadora de independência entre as características.

→ Spam, textos e classificação.

Redes Neurais

Aprendem relações complexas por meio de camadas de neurônios artificiais.

→ Imagens, áudio, texto e problemas complexos.

02 Não supervisionado

Os dados não têm resposta ou rótulo informado. O algoritmo procura estruturas, semelhanças ou relações existentes nos próprios dados.

→ Rotulados: NÃO · Objetivo: descobrir padrões · Saída: grupos ou representações.

K-Means

Agrupa os dados em K grupos de acordo com a similaridade.

→ Segmentação de clientes.

DBSCAN

Forma grupos a partir de regiões densas e consegue identificar pontos considerados ruído.

→ Detecção de grupos e anomalias.

Clustering Hierárquico

Constrói uma hierarquia de grupos, permitindo visualizar relações entre os elementos.

→ Segmentação e análise exploratória.

PCA

Reduz o número de variáveis preservando o máximo possível da variância dos dados.

→ Visualização e redução de dimensionalidade.

Autoencoders

Redes neurais que aprendem representações compactas dos dados.

→ Redução, representação e detecção de anomalias.

03 Semi-supervisionado

Usa uma pequena quantidade de dados rotulados junto com uma grande quantidade de dados não rotulados. Útil quando obter rótulos exige tempo, conhecimento especializado ou alto custo.

→ Rotulados: PARCIALMENTE · Objetivo: aprender com poucos rótulos.

Pseudo-rotulagem

O modelo atribui rótulos provisórios aos dados não rotulados com base nas próprias previsões.

Self-Training

Treina primeiro com dados rotulados e usa as previsões mais confiáveis para ampliar o conjunto de treinamento.

Label Propagation

Propaga a informação dos exemplos rotulados para exemplos semelhantes não rotulados.

Consistency Regularization

Incentiva o modelo a produzir previsões consistentes mesmo quando os dados sofrem pequenas alterações.

04 Por reforço

Um agente interage com um ambiente: executa ações, recebe recompensas ou penalidades e aprende uma política para maximizar a recompensa acumulada.

→ Sinal de aprendizado: recompensa/penalidade · Saída: ação ou política.

Q-Learning

Aprende o valor esperado de ações em determinados estados.

→ Jogos e navegação.

SARSA

Aprende valores de ação considerando a política que está sendo executada.

→ Controle e ambientes sequenciais.

Deep Q-Network (DQN)

Combina Q-Learning com redes neurais profundas para lidar com estados complexos.

→ Jogos e agentes inteligentes.

Policy Gradient
Aprende diretamente uma política que determina quais ações o agente deve executar.
→ Controle contínuo e robótica.

Actor-Critic
Combina um ator, que escolhe as ações, e um crítico, que avalia essas ações.
→ Robótica e agentes complexos.

05 Comparação rápida

Os quatro tipos lado a lado: rótulos, objetivo, saída e exemplo.

Supervisionado
Rotulados: sim · Objetivo: prever · Saída: classe ou valor.
→ Prever doença.

Não supervisionado
Rotulados: não · Objetivo: descobrir padrões · Saída: grupos ou representações.
→ Segmentar clientes.

Semi-supervisionado
Rotulados: parcialmente · Objetivo: aprender com poucos rótulos · Saída: classe ou representação.
→ Classificar imagens.

Por reforço
Sinal: recompensa/penalidade · Objetivo: aprender ações · Saída: ação ou política.
→ Jogar um jogo.

06 Fluxo de um projeto

As dez etapas básicas de um projeto de Machine Learning, na ordem.

1. Definir o problema
Deixar claro o objetivo e o que conta como sucesso.

2. Coletar os dados
Reunir as fontes de dados necessárias.

3. Limpar e preparar
Tratar valores faltantes, erros e formatos.

4. Explorar e analisar
Entender distribuições, relações e problemas nos dados.

5. Separar treino, validação e teste
Dividir os dados para avaliar de forma honesta, quando aplicável.

6. Escolher o algoritmo
Selecionar o método adequado ao tipo de problema.

7. Treinar o modelo
Ajustar os parâmetros do modelo com os dados de treino.

8. Avaliar o desempenho
Medir os resultados com métricas adequadas ao problema.

9. Ajustar hiperparâmetros
Refinar as configurações para melhorar o modelo.

10. Produção e monitoramento
Colocar o modelo em uso e acompanhar seu desempenho ao longo do tempo.

07 Métricas

A métrica deve ser escolhida de acordo com o problema.

Classificação

Métricas comuns quando a saída é uma categoria.

- **Accuracy**
  Proporção de acertos sobre o total de previsões.
- **Precision**
  Entre os casos previstos como positivos, quantos realmente eram.
- **Recall**
  Entre os casos realmente positivos, quantos o modelo encontrou.
- **F1-score**
  Combina precision e recall em um único número.
- **Matriz de confusão**
  Tabela que mostra acertos e erros por classe.

Regressão

Métricas comuns quando a saída é um valor numérico.

- **MAE**
  Erro absoluto médio entre previsão e valor real.
- **MSE**
  Erro quadrático médio: penaliza mais os erros grandes.
- **RMSE**
  Raiz do MSE, na mesma unidade da variável prevista.
- **R^2**
  Quanto da variação dos dados o modelo consegue explicar.

08 Conceitos-chave

Vocabulário essencial de Machine Learning.

Dataset

Conjunto de dados usado no processo de aprendizado.

Feature

Característica ou variável usada pelo modelo.

Label

Resposta ou classe conhecida em dados supervisionados.

Modelo

Representação matemática/computacional aprendida a partir dos dados.

Treinamento

Processo de ajuste dos parâmetros do modelo.

Hiperparâmetro

Configuração definida antes ou durante o treinamento.

Overfitting

O modelo aprende demais os dados de treino e perde capacidade de generalizar.

Underfitting

O modelo é simples demais para capturar os padrões relevantes.

09 Exemplo prático

Um hospital quer identificar se uma imagem apresenta determinada condição.

- **Com imagens já classificadas**
  Se especialistas já rotularam as imagens, um modelo supervisionado pode aprender com esses exemplos.
- **Com muitas imagens sem rótulo**
  Técnicas não supervisionadas ou semi-supervisionadas ajudam a explorar e aproveitar esses dados.